王晨捷



意向方向：训练 AI Infra 实习生

邮箱：wang-cj23@mails.tsinghua.edu.cn

基本情况

教育： **清华大学 计算机系 大三在读** | 平均绩点 3.91，年级排名 24/197

数学： 微积分、高等线性代数选讲、复变函数等基础数学课均为满绩。

编程： C++、Python、Rust、Java 等编程经历，相关课程全部满绩。

Infra： **掌握 CUDA 编程，了解 Hopper & Blackwell 底层架构及新特性**；理解基础的通信与各种并行方式，了解 Flash Attention；能使用 Nsight Systems（nsys）做性能分析。

英语： 六级 601 分，阅读 245/249。

实习与研究经历

清华 TSAIL 实验室 | 具身智能 & 强化学习

2026.03 - 2026.06

指导老师：苏航 · 参与具身智能方向科研，对强化学习（RL）、多模态模型有基本的了解。

可灵 | 训练 AI Infra 实习生

2026.06 - 至今

★ **可图（Kolors）训练显存优化**：在 Hopper GPU 上将峰值显存从 **140 GB 降至 70 GB**，并参与训练全阶段优化。

- **可灵 V4 / V4 Pro 训练 MoE 优化**（Blackwell GPU）
  - ★ **MXFP8 改造：** ① 设计 & 调优 SonicMoE 的 MXFP8 方案，MXFP8 覆盖部分（含量化开销）相对 BF16 加速 **1.85×**，**端到端提速 10%**；② 验证精度损失对模型训练及 MoE 负载均衡的影响，推动上线。
  - **SonicMoE 改进：** ① **显存优化**——分 chunk 计算、复用显存 buffer，改造为带重计算的方案；② **改造 GEMM 调度方式**，缓解 ReduceScatter 与 GEMM 争抢 SM 导致的效率退化。
  - **Router Tensor Core 改造：** 用 3 个 BF16 精确表示 FP32，并将累加从 TMEM 转移到寄存器，截断 Tensor Core 自带的向零舍入偏差，实测精度高于原本 FP32 GEMM。router 整体加速 **4.2×**，**端到端提速 5%**。

竞赛经历

★ 第十三届并行应用挑战赛（PAC 2026） | 优化赛道特等奖 | 指导老师：翟季冬

2026.07 - 2026.10

队长（pacUltra） · 优化赛道 244 支队伍 · 平台：灵晟超算（鲲鹏 920F）

- **FP64 三张量缩并：** 计算与跨 NUMA 通信重叠、多级任务划分、线程分工与汇编内核，实测达理论峰值约 **3/4**。
- **稀疏注意力 Indexer 融合算子：** 结合硬件特点做了量化，用 INT8 矩阵运算替代 BF16；该量化方案可以用浮点运算直接操作 INT32 寄存器，在满足精度要求的前提下，实测**超过原生 BF16 的理论峰值**。

鲲鹏高性能计算全球挑战赛（S2 赛季） | 三个赛题全部第一名

2026.09

队长（kunUltra） · 484 支参赛队伍 · **获奖金 10 万元** · 平台：灵晟超算（鲲鹏 920F）

- 优化 CONV（卷积）、TRSM（三角求解）、ZGEMM（复数矩阵乘）三道赛题。

SC26 国际大学生超算竞赛 | 线上赛道

2026.09 - 至今

队员，参与 **MFC** 赛题 · 全球 10 个国家 29 支队伍入选

- MFC 是基于 Fortran 的开源流体力学求解器，主要做其在 Hopper GPU 上的性能调优。

清华大学超算队

2026.04 - 至今

队员 · 为超算队 CUDA 教程撰写 **Hopper 架构 & 新特性**章节